


Choisir la bonne famille de ML — *le raisonnement en amont*


Avant tout code : cadrer le problème → en déduire la famille de modèles · Marianne A.

L'idée. On ne choisit pas un algorithme « parce qu'il est à la mode » : le choix se déduit de la *nature du problème*, **avant** d'écrire la moindre ligne de code. **Étape 0** Et d'abord — **ai-je vraiment besoin de ML ?** Si une règle métier simple suffit, on s'en passe. Le ML sert quand la règle est *trop complexe à écrire à la main* et qu'on a des *données* pour l'apprendre.

1 L'arbre de décision : les 4 grandes voies, puis le détail du ML classique



▼ Détail de la voie ML classique (données structurées) :



Les trois autres voies (données non structurées, génération, décisions) sont développées ci-dessous ↓

2 Au-delà du ML tabulaire : les autres paradigmes

Deep Learning

données non structurées — analyser / classer

QUAND

Image, texte, audio ou vidéo à **classer, détecter, transcrire** (tâche « discriminative », on ne génère pas).

DOMAINES & ARCHITECTURES

- **Image** → CNN (ResNet, EfficientNet), Vision Transformers · classification, détection (YOLO), segmentation
- **Texte** → Transformers / NLP (BERT) · sentiment, NER, classification
- **Audio** → spectrogrammes + CNN/Transformers · reconnaissance vocale
- **Séries temporelles** complexes → RNN / LSTM, Temporal CNN

À SAVOIR

Gourmand en **données & GPU**. On part presque toujours d'un modèle **pré-entraîné** qu'on adapte (transfer learning).

GenAI / LLM

générer / comprendre du contenu

QUAND

Produire ou transformer du **contenu** — texte, code, image ; dialoguer, résumer, extraire, traduire.

MODÈLES

- **LLM** (GPT, Llama, Mistral) pour le texte / code
- Modèles de **diffusion** pour l'image

COMMENT ON L'ADAPTE

Échelle de complexité croissante : **prompt** → **RAG** → **fine-tuning** → **agent**. On ne ré-entraîne pas de zéro, on adapte un modèle de fondation.

DÉTAIL

→ Voir la fiche dédiée « *GenAI / LLM / Agents : quand & comment* ».

Apprentissage par renforcement

une suite de décisions à optimiser

QUAND

Un **agent** prend une **séquence de décisions** dans un environnement pour maximiser une **récompense** — pas juste une prédiction isolée.

EXEMPLES

- Robotique, contrôle industriel
- Jeux, simulation
- Optimisation, certains cas de trading

APPROCHES

Q-learning, DQN, Policy Gradient, PPO.

À SAVOIR

Nécessite un **environnement / simulateur** ; coûteux et spécialisé — **rarement** le premier réflexe.

3 Les critères qui affinent le choix (une fois la famille trouvée)

CRITÈRE	LA QUESTION À SE POSER	CE QUE ÇA ORIENTE
Nature des données	Tabulaire, ou image / texte / audio ?	Tabulaire → arbres & boosting dominant. Non structuré → deep learning .
Étiquettes disponibles	Ai-je des exemples avec la bonne réponse ?	Oui → supervisé . Non → non supervisé . Peu d'étiquettes → semi-supervisé.
Interprétabilité	Dois-je <i>expliquer</i> chaque décision (réglementaire, métier) ?	Oui → linéaire / arbre simple . Non → boosting / réseaux de neurones acceptables.
Volume de données	Combien de lignes ai-je ?	Peu → modèles simples & régularisés . Beaucoup → boosting, réseaux de neurones.

CRITÈRE	LA QUESTION À SE POSER	CE QUE ÇA ORIENTE
Dimension	Beaucoup de variables par rapport au nb de lignes ?	Haute dimension → régularisation (Ridge/Lasso) et/ou réduction de dimension .
Déséquilibre des classes	Une classe est-elle très rare ?	Oui → métrique F1 macro / rappel , <code>class_weight</code> , rééchantillonnage.
Ressources & latence	Contraintes de calcul, temps de réponse en prod ?	Serré → linéaire / RF (rapides). Large → boosting / deep learning.
Besoin de probabilités	Ai-je besoin de probabilités <i>fiables</i> , pas juste d'une classe ?	Oui → régression logistique (bien calibrée) ou calibration a posteriori.

La règle d'or (anti-sur-ingénierie). Une fois la famille identifiée, on **commence simple** : une baseline (linéaire pour le tabulaire) qui sert d'étalon, puis on monte en complexité *seulement si ça apporte* une amélioration mesurable. Sur données tabulaires, le trio gagnant reste **linéaire régularisé + Random Forest + boosting** — à comparer honnêtement. Et ça vaut pour la GenAI : **un LLM n'est pas la réponse à un problème tabulaire** — commence par la voie la plus simple qui marche. → Fiches liées : « *Principaux algorithmes de Machine Learning* » (détail des candidats ML) et « *GenAI / LLM / Agents* » (si le problème est génératif).

À retenir. 0) Est-ce vraiment du ML ? 1) Quelle voie ? (ML classique tabulaire · deep learning non structuré · GenAI génératif · renforcement) 2) En ML classique : ai-je une cible Y ? → régression / classification / clustering / réduction / anomalies / association. 3) J'affine avec les critères (interprétabilité, volume, dimension, déséquilibre...). Le problème dicte la famille, pas l'inverse.